

# **Automatentheorie und Formale Sprachen**

## **– LV 4110 –**

### **Grammatiken und Formale Sprachen**

- 
- Kennenlernen der Begriffe: **Formale Sprachen** und **Ableitung**
  - Definition eines allgemeinen **Erzeugungs-** bzw. **Ableitungssystems**
  - Klärung, was man unter der **Sprache einer Grammatik** versteht
  - Definition und Einteilung der Chomsky-Grammatik (**Chomsky-Hierarchie** bzw. **-Typen 0 bis 3**)
  - Festlegung, was das **allgemeine Wortproblem** ausdrückt
  - Konstruktion einer Grammatik aus gegebenem Automaten und umgekehrt
  - Kennenlernen des Vorgehens bei der Erstellung von **Ableitungsbäumen**
-

## III. Grammatiken und Formale Sprachen

1. Semi-Thue-Systeme
    - 1.1 Idee und Definition des Systems
    - 1.2 Ableitung und Überführung
  2. Chomsky-Grammatiken
    - 2.1 Idee und Definition
    - 2.2 Sprache einer Chomsky-Grammatik
  3. Chomsky-Hierarchie
  4. Endliche Automaten und RL-Grammatiken
    - 4.1 Konstruktion einer Grammatik aus einem Automaten
    - 4.2 Konstruktion eines Automaten aus einer Grammatik
-

bisher:

Sprachen mit Hilfe von **Automaten** identifiziert und analysiert

jetzt:

Kennenlernen von Formalismen zur **Erzeugung** von Sprachen  
→ Erzeugungssysteme

Solche Erzeugungssysteme, die auf sog. **REGELN, PRODUKTIONEN** oder **GRAMMATIKEN** basieren, sind Untersuchungsgegenstand der Theorie der Formalen Sprachen.

## III. Grammatiken und Formale Sprachen

### 1. Semi-Thue-Systeme

#### 1.1 Idee und Definition des Systems

#### 1.2 Ableitung und Überführung

### 2. Chomsky-Grammatiken

#### 2.1 Idee und Definition

#### 2.2 Sprache einer Chomsky-Grammatik

### 3. Chomsky-Hierarchie

### 4. Endliche Automaten und RL-Grammatiken

#### 4.1 Konstruktion einer Grammatik aus einem Automaten

#### 4.2 Konstruktion eines Automaten aus einer Grammatik

---

## Idee:

- Sprache nicht rein als eine Menge von Wörtern ansehen, sondern **definieren**, wie man Wörter **verändern** und **manipulieren** kann.
- Diese Manipulationen müssen kontrollierbar und nachvollziehbar sein und deshalb nach **festen Regeln** ablaufen.

## Definition:

Ein **Semi-Thue-System** (Norwegischer Mathematiker A. Thue, 1914) wird durch eine endliche Teilmenge  $\mathbf{P} \subseteq \Sigma^* \times \Sigma^*$  bestimmt. Jedes Wortpaar  $(\alpha, \beta) \in \mathbf{P}$  ist eine **Regel** in dem Sinne, dass in einem vorhandenen Ausgangswort  $\mathbf{w}$  ein Teilwort  $\alpha$  durch  $\beta$  ersetzt werden kann. Durch die einseitige Ersetzungsrichtung  $\alpha \rightarrow \beta$  erklärt sich die Bezeichnung "Semi" .

## III. Grammatiken und Formale Sprachen

1. Semi-Thue-Systeme
    - 1.1 Idee und Definition des Systems
    - 1.2 Ableitung und Überführung**
  2. Chomsky-Grammatiken
    - 2.1 Idee und Definition
    - 2.2 Sprache einer Chomsky-Grammatik
  3. Chomsky-Hierarchie
  4. Endliche Automaten und RL-Grammatiken
    - 4.1 Konstruktion einer Grammatik aus einem Automaten
    - 4.2 Konstruktion eines Automaten aus einer Grammatik
-

---

## Definition:

Ein Wort **w** heißt aus einem Wort **v** **ableitbar**, wenn es durch endlich viele **Ersetzungsschritte** aus **v** entsteht.

## Notation:

$v \Rightarrow^* w : v(\alpha_1 \rightarrow \beta_1) \Rightarrow v_1(\alpha_2 \rightarrow \beta_2) \Rightarrow \dots \Rightarrow v_{n-1}(\alpha_n \rightarrow \beta_n) \Rightarrow v_n = w$

## kurz:

**$v \Rightarrow^* w$**   $:=$  **w** aus **v** **ableitbar** oder  
**v** in **w** **überführbar**



### Beispiel:

$$\Sigma = \{a, b, c, d, e\}$$

$$v = \{abc\}$$

$$w = \{aeb\}$$

Regeln des Semi-Thue-Systems **R**:

$$(1) \quad ab \rightarrow ad$$

$$(4) \quad ad \rightarrow ae$$

$$(2) \quad dc \rightarrow ee$$

$$(5) \quad eb \rightarrow b$$

$$(3) \quad e \rightarrow b$$

$$(6) \quad abc \rightarrow e$$

Ableitung:  $v \Rightarrow^* w$

$$v = \underline{abc} \xRightarrow{(1)}^* \underline{ad}c \xRightarrow{(2)}^* ae\underline{e} \xRightarrow{(3)}^* ae\underline{b} = w \quad \text{q.e.d.}$$

## III. Grammatiken und Formale Sprachen

1. Semi-Thue-Systeme
    - 1.1 Idee und Definition des Systems
    - 1.2 Ableitung und Überführung
  - 2. Chomsky-Grammatiken**
    - 2.1 Idee und Definition**
    - 2.2 Sprache einer Chomsky-Grammatik
  3. Chomsky-Hierarchie
  4. Endliche Automaten und RL-Grammatiken
    - 4.1 Konstruktion einer Grammatik aus einem Automaten
    - 4.2 Konstruktion eines Automaten aus einer Grammatik
-

---

Amerikanischer Sprachwissenschaftler **Noam Chomsky**, 50. Jahren

Idee:

- Das Alphabet  $\Sigma$  besteht aus zwei disjunkten Teilmengen **T** und **N**.
- **T** steht für die Menge der **Terminalsymbole**, d. h. Menge atomarer Zeichen, aus denen letztlich alle Wörter einer Sprache aufgebaut sind.

Bsp.: Zeichen a, b, ..., z und 0, 1, ..., 9

- **N** steht für die Menge der **Nonterminalsymbole**, die zur Abstraktion und Klassenbildung von Wörtern dienen; sog. syntaktische Kategorien

Bsp.: Begriffe wie <Name>, <Buchstabe>, <Ziffern>

### Beispiel: „Namensgebung in PASCAL“

hier: erweiterte Backus-Naur-Form (BNF)

$\langle \text{Name} \rangle ::= \langle \text{Buchstabe} \rangle \{ \langle \text{Buchstabe} \rangle \mid \langle \text{Ziffer} \rangle \}$

$\langle \text{Buchstabe} \rangle ::= a \mid b \mid c \mid \dots \mid z$

$\langle \text{Ziffer} \rangle ::= 0 \mid 1 \mid 2 \mid \dots \mid 9$

$::=$  Überführung oder Ersetzung

$\mid$  Auswahl unter mehreren Alternativen

$\{ \dots \}$  beliebige Wiederholung

Ergebnis: Ein korrekter Name muss mit einem Buchstaben beginnen, anschließend können weitere Buchstaben und Ziffern in beliebiger Zahl folgen.

## Definition:

Unter einer **Chomsky-Grammatik** verstehen wir ein **Quadrupel**  $G = (\mathbf{N}, \mathbf{T}, \mathbf{P}, S)$ , wobei  $\mathbf{P}$  ein **Semi-Thue-System** über dem Alphabet  $\Sigma^* = (\mathbf{N} \cup \mathbf{T})^*$  ist. Die einzelnen Komponenten haben folgende Bedeutung:

- N** Menge der Nonterminalsymbole  $A, B, C, \dots$
- T** Menge der Terminalsymbole  $a, b, c, \dots$
- P** Menge der Produktionen (Regeln):  
 $\mathbf{P} \subset \{ \varphi \rightarrow \psi \mid \varphi, \psi \in (\mathbf{N} \cup \mathbf{T})^*, \varphi \neq \varepsilon \}$
- S** Startsymbol  $\in \mathbf{N}$ , das in mindestens einer Regel links vorkommt

### Interpretation:

- Man hat endliche Menge von Produktionen **P** ( $\rightarrow$  auch Regeln genannt), die Terminal- und Nonterminalsymbole beinhalten können.
- Erzeugung von Wörtern beginnt immer mit dem Startsymbol **S**.
- Linke Seite einer Regel darf nicht das leere Wort  $\varepsilon$  sein.
- Die erzeugenden Wörter bestehen letztendlich nur aus Terminalzeichen **T**.

## III. Grammatiken und Formale Sprachen

1. Semi-Thue-Systeme
  - 1.1 Idee und Definition des Systems
  - 1.2 Ableitung und Überführung
2. Chomsky-Grammatiken
  - 2.1 Idee und Definition
  - 2.2 Sprache einer Chomsky-Grammatik**
3. Chomsky-Hierarchie
4. Endliche Automaten und RL-Grammatiken
  - 4.1 Konstruktion einer Grammatik aus einem Automaten
  - 4.2 Konstruktion eines Automaten aus einer Grammatik

## Definition:

Die Sprache einer Chomsky-Grammatik besteht aus allen Worten aus  $T^*$ , die aus  $S$  ableitbar sind, d. h. für die gilt:

$$L(G) = \{ w \in T^* \mid S \Rightarrow^* w \}.$$

heißt:

$$S \Rightarrow u_1 \Rightarrow u_2 \Rightarrow \dots \Rightarrow u_n = w$$

mit  $n \in \mathbb{N}_0$

$$u_i \in (N \cup T)^*$$

$$w \in T^*$$

kurz:  $S \Rightarrow^* w$



---

Beispiel: „Namensgebung in PASCAL“

Mit

$$\mathbf{N} = \{ \langle \text{Name} \rangle, \langle \text{Buchstabe} \rangle, \langle \text{Ziffer} \rangle \}$$

$$\mathbf{T} = \{ a, b, c, \dots, z, 0, 1, 2, \dots, 9 \}$$

$$\mathbf{P} = \{ \langle \text{Name} \rangle \rightarrow \langle \text{Name} \rangle \langle \text{Ziffer} \rangle, \langle \text{Name} \rangle \rightarrow \langle \text{Buchstabe} \rangle, \\ \langle \text{Buchstabe} \rangle \rightarrow a \mid b \mid c \mid \dots \mid z, \langle \text{Ziffer} \rangle \rightarrow 0 \mid 1 \mid 2 \mid \dots \mid 9 \}$$

$$\mathbf{S} = \langle \text{Name} \rangle$$

gehört das Wort „**a12**“ zur Sprache  $L(G)$  obiger Grammatik

**$G = (\mathbf{N}, \mathbf{T}, \mathbf{P}, \mathbf{S})$** , weil sich folgende Ableitung angeben lässt:

$$\begin{aligned} \underline{\langle \text{Name} \rangle} &\rightarrow \underline{\langle \text{Name} \rangle} \langle \text{Ziffer} \rangle \rightarrow \underline{\langle \text{Name} \rangle} \langle \text{Ziffer} \rangle \langle \text{Ziffer} \rangle \\ &\rightarrow \underline{\langle \text{Buchstabe} \rangle} \underline{\langle \text{Ziffer} \rangle} \underline{\langle \text{Ziffer} \rangle} \rightarrow \mathbf{a12} \end{aligned}$$

## III. Grammatiken und Formale Sprachen

1. Semi-Thue-Systeme
  - 1.1 Idee und Definition des Systems
  - 1.2 Ableitung und Überführung
2. Chomsky-Grammatiken
  - 2.1 Idee und Definition
  - 2.2 Sprache einer Chomsky-Grammatik
- 3. Chomsky-Hierarchie**
4. Endliche Automaten und RL-Grammatiken
  - 4.1 Konstruktion einer Grammatik aus einem Automaten
  - 4.2 Konstruktion eines Automaten aus einer Grammatik

## Grundsätzliche Bemerkung:

Die bisherige Definition einer Chomsky-Grammatik ist so allgemein, dass nicht entscheidbar ist, ob ein Wort zur Sprache einer vorgegebenen Grammatik gehört oder nicht (vgl. allgemeines Wortproblem).

Deshalb ist es sinnvoll, Einschränkungen zu treffen, so dass dieses Problem lösbar wird.

⇒ vernünftige Hierarchie von Einschränkungen!

Im folgenden wollen wir uns einer entsprechenden Einteilung (Typ 0 bis Typ 3) zuwenden.

---

## Definition:

Eine Chomsky-Grammatik  $G = (\mathbf{N}, \mathbf{T}, \mathbf{P}, \mathbf{S})$  heißt

- **Typ 0** oder **allgemeine** Chomsky-Grammatik, wenn alle Regeln die **nicht eingeschränkte** Form

$\alpha \rightarrow \beta$  mit  $\alpha \neq \varepsilon$   $\varepsilon = \text{leeres Element}$

$\alpha, \beta \in (\mathbf{N} \cup \mathbf{T})^*$

haben ( $\rightarrow$  Ursprungs-Definition!).

## Definition:

Eine Chomsky-Grammatik  $G = (\mathbf{N}, \mathbf{T}, \mathbf{P}, S)$  heißt

- **Typ 1** oder **kontextsensitive** Grammatik, wenn alle Regeln die Form

$$\alpha \mathbf{A} \beta \rightarrow \alpha \gamma \beta \quad \text{mit} \quad \gamma \neq \varepsilon$$

$$\mathbf{A} \in \mathbf{N} ; \quad \alpha, \beta, \gamma \in (\mathbf{N} \cup \mathbf{T})^*$$

haben mit der Ausnahme, dass  $S \rightarrow \varepsilon$  dazugehören darf, wenn  $S$  in keiner Regel auf der rechten Seite auftritt.

## Definition:

Eine Chomsky-Grammatik  $G = (N, T, P, S)$  heißt

- **Typ 2** oder **kontextfreie** Grammatik, wenn alle Regeln die Form

$$A \rightarrow \gamma \quad \text{mit} \quad A \in N ; \quad \gamma \in (N \cup T)^*$$

$$\text{oder} \quad \gamma = \varepsilon$$

haben.

## Definition:

Eine Chomsky-Grammatik  $G = (\mathbf{N}, \mathbf{T}, \mathbf{P}, S)$  heißt

- **Typ 3** oder **rechtslineare<sup>\*)</sup>** Grammatik, wenn alle Regeln die Form

$$A \rightarrow \varepsilon ; A \rightarrow a \quad \text{oder} \quad A \rightarrow aB ;$$

$$\text{mit} \quad a \in \mathbf{T} ;$$

$$A, B \in \mathbf{N}$$

haben.

<sup>\*)</sup> d. h. nur ein **N**onterminalsymbol ganz rechts!

### Anmerkung:

Jede Typ-3-Grammatik ist auch vom Typ 2, und jede Typ-1-Grammatik auch vom Typ 0.

### Definition:

Zwei Grammatiken heißen **äquivalent**, wenn sie die gleiche Sprache erzeugen.

### Definition:

Eine Sprache  $L(G)$  heißt vom **Chomsky-Typ  $i$**  ( $i=0,1,2,3$ ) wenn  $G$  vom Typ  $i$  ist. Die Familie der Sprachen vom Typ  $i$  wird mit  $L_i$  bezeichnet.

### Satz:

Es gelten die Beziehungen:  $L_3 \subset L_2 \subset L_1 \subset L_0$  und  
$$L_3 = \{ L(A) \mid A \text{ ist endlicher Automat} \}$$

---



## III. Grammatiken und Formale Sprachen

1. Semi-Thue-Systeme
    - 1.1 Idee und Definition des Systems
    - 1.2 Ableitung und Überführung
  2. Chomsky-Grammatiken
    - 2.1 Idee und Definition
    - 2.2 Sprache einer Chomsky-Grammatik
  3. Chomsky-Hierarchie
  - 4. Endliche Automaten und RL-Grammatiken**
    - 4.1 Konstruktion einer Grammatik aus einem Automaten
    - 4.2 Konstruktion eines Automaten aus einer Grammatik
-

Die Regeln der rechts- (oder links-) linearen Grammatiken sind innerhalb der Chomsky-Hierarchie am stärksten eingeschränkt.

**rechtslinear:**  $A \rightarrow aB$

Nonterminal- zeichen <b>A</b>	nur ersetzbar durch	Terminal- zeichen <b>a</b>	+ ggf. Nonterminal- zeichen <b>B</b>
-------------------------------------	---------------------------	----------------------------------	---

Bei Rechtslinearität erfolgt Einsetzung immer **rechts**, d. h. am Ende des bereits abgeleiteten Wortes.

Da immer nur ein zusätzliches Terminalzeichen hinzugefügt wird, wächst das entstehende Wort in einer Richtung **linear** mit der Anzahl der Ersetzungsschritte.

Satz:

Zu jeder **rechtslinearen** Grammatik gibt es eine **linkslineare**, die die gleiche Sprache erzeugt.

Satz:

Zu jeder rechtslinearen Grammatik mit der Sprache  $L(G)$  gibt es einen endlichen Automaten mit

$$L(A) = L(G)$$

und umgekehrt.

## III. Grammatiken und Formale Sprachen

1. Semi-Thue-Systeme
    - 1.1 Idee und Definition des Systems
    - 1.2 Ableitung und Überführung
  2. Chomsky-Grammatiken
    - 2.1 Idee und Definition
    - 2.2 Sprache einer Chomsky-Grammatik
  3. Chomsky-Hierarchie
  4. Endliche Automaten und RL-Grammatiken
    - 4.1 Konstruktion einer Grammatik aus einem Automaten**
    - 4.2 Konstruktion eines Automaten aus einer Grammatik
-

---


Konstruktion einer RL  $G$  aus einem  $A = (\mathbf{S}, s_0, \mathbf{F}, \Sigma, \delta)$ :

- verwende die Eingabezeichen  $\Sigma$  als Terminalzeichen  $\mathbf{T}$
- verwende die Menge  $\mathbf{S}$  der Zustände als Nonterminalzeichen  $\mathbf{N}$
- verwende  $s_0$  als Startsymbol  $\mathbf{S}$
- ersetze jeden Funktionswert  $\delta(\mathbf{s1}, \mathbf{a}) = \mathbf{s2}$  durch die Regel  $\mathbf{s1} \rightarrow \mathbf{a s2}$
- erzeuge für jeden Endzustand  $s_f$  eine zusätzliche Regel  $\mathbf{s_f} \rightarrow \varepsilon$

## Ungerade Anzahl von Einsen:

Wir betrachten folgenden DFA, der alle Worte akzeptiert, die eine ungerade Anzahl von Einsen enthalten.

DFA  $\mathbf{A} = (\Sigma, \mathbf{S}, S_0, \delta, \mathbf{F})$  mit  $\Sigma = \{0, 1\}$ ,  $\mathbf{S} = \{S_0, S_1\}$ ,  $\mathbf{F} = \{S_1\}$  und  $\delta$  gemäß folgendem Zustandsdiagramm:



## Ungerade Anzahl von Einsen:

Hierauf folgt unter Anwendung der Regeln die Grammatik  $G = (\mathbf{N}, \mathbf{T}, \mathbf{P}, S)$  mit

- Eingabezeichen  $\Sigma$  als Terminalzeichen  $\mathbf{T} \rightarrow \mathbf{T} = \Sigma = \{0, 1\}$
- Zustandsmenge  $\mathbf{S}$  als Nonterminalzeichen  $\mathbf{N} \rightarrow \mathbf{N} = \{S_0, S_1\}$
- Anfangszustand  $S_0$  als Startsymbol  $S \rightarrow S = S_0$
- Jeder Funktionswert  $\delta(s_1, a) = s_2$  eine Regel der Form  $s_1 \rightarrow a s_2 \rightarrow \mathbf{P} = \{ S_0 \rightarrow 1 S_1, S_0 \rightarrow 0 S_0, S_1 \rightarrow 1 S_0, S_1 \rightarrow 0 S_1 \}$
- Jeden Endzustand  $s_f$  eine zusätzliche Regel  $s_f \rightarrow \varepsilon \rightarrow S_1 \rightarrow \varepsilon$   
 $\Rightarrow \mathbf{P}$  und  $\delta$  sind **ähnlich ausdrucksstarke** Konzepte!

## III. Grammatiken und Formale Sprachen


1. Semi-Thue-Systeme
  - 1.1 Idee und Definition des Systems
  - 1.2 Ableitung und Überführung
2. Chomsky-Grammatiken
  - 2.1 Idee und Definition
  - 2.2 Sprache einer Chomsky-Grammatik
3. Chomsky-Hierarchie
4. Endliche Automaten und RL-Grammatiken
  - 4.1 Konstruktion einer Grammatik aus einem Automaten
  - 4.2 Konstruktion eines Automaten aus einer Grammatik**



### Konstruktion eines A aus einer RL $G = (N, T, P, S)$ :

- verwende die Terminalzeichen  $T$  als Eingabezeichen  $\Sigma$
- verwende die Nonterminalzeichen  $N$  als Zustände  $S$
- verwende das Startsymbol  $S$  als Ausgangszustand  $s_0$
- verwende jedes  $A$ , für das  $A \rightarrow \varepsilon$  gilt, als Endzustand  $s_f$
- ersetze jede Produktion  $A \rightarrow aB$  durch einen Funktionswert  $\delta(A, a) = B$
- führe für **alle** Produktionen  $A \rightarrow a$  *einen* Endzustand  $s_f$  ein und
- bilde für **jede** solche Produktion den Funktionswert  $\delta(A, a) = s_f$

## Ableitungsbaum des Wortes **aaabbb**:



Blätter von links nach rechts  
gelesen ergeben das Wort w.